UNIVERSIDAD CENTRAL DE VENEZUELA
FACULTAD DE CIENCIAS
ESCUELA DE COMPUTACIÓN
CÁLCULO CIENTÍFICO

Taller I: Compresión de Imágenes mediante SVD

Semestre 2026-I

Integrantes:
Carlos Paccagnella. C.I.: 31.752.534
Diego León. C.I.: 31.549.189

Fecha: 23 de mayo de 2026

1. Introducción

La Descomposición en Valores Singulares (SVD, por sus siglas en inglés) representa una de las herramientas algebraicas y numéricas más potentes para el procesamiento de señales, el análisis de datos y la reducción de dimensionalidad. En el contexto de las imágenes digitales, una fotografía puede ser tratada matemáticamente como una matriz de intensidades de píxeles.

Este informe documenta la implementación computacional y el análisis cuantitativo de la aproximación de rango bajo aplicada a la compresión de imágenes. El objetivo principal es evaluar cómo la eliminación de componentes estadísticas secundarias permite reducir drásticamente el espacio de almacenamiento requerido por un archivo digital sin comprometer severamente su interpretabilidad visual.

2. Fundamento Teórico

Sea $A \in \mathbb{R}^{m \times n}$ una matriz real de rango r que representa una imagen en escala de grises. Su descomposición SVD viene dada por la expresión:

$$A = U\Sigma V^T = \sum_{i=1}^{r} \sigma_i u_i v_i^T \tag{1}$$

Donde las matrices involucradas cumplen con las siguientes propiedades:

- $U \in \mathbb{R}^{m \times m}$ es una matriz ortogonal cuyas columnas son los vectores singulares izquierdos de A, representando los patrones geométricos verticales de la imagen.
- $V \in \mathbb{R}^{n \times n}$ es una matriz ortogonal cuyas columnas son los vectores singulares derechos de A (y por ende las filas de V^T representan los patrones horizontales).
- $\Sigma \in \mathbb{R}^{m \times n}$ es una matriz diagonal que contiene los valores singulares ordenados de manera decreciente según su nivel de importancia o peso estadístico: $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$.

El **Teorema de Eckart-Young-Mirsky** provee el sustento matemático para la compresión. Este establece que la mejor aproximación de rango k (con $k < r$) para la matriz A, en términos de la norma de Frobenius, es la matriz A_k obtenida al truncar la suma en el k-ésimo término:

$$A_k = \sum_{i=1}^{k} \sigma_i u_i v_i^T \tag{2}$$

Esta matriz A_k minimiza el error $\|A - A_k\|_F$, garantizando que ninguna otra matriz de rango k capture mayor varianza o energía de los datos originales.

3. Implementación Computacional

El desarrollo experimental se construyó utilizando el lenguaje de programación `Python` en el entorno interactivo `Google Colab`. Se procesó la imagen convirtiéndola a escala de grises para obtener una matriz de intensidades $A \in \mathbb{R}^{m \times n}$. En la Figura 1 se puede apreciar el contraste entre el archivo de entrada original a color y la matriz de luminancia correspondiente. Posteriormente, se calculó la SVD completa de la matriz de intensidades, obteniendo las matrices ortogonales en sus dimensiones íntegras antes de proceder a aislar los componentes principales.

3.1. Escala de grises

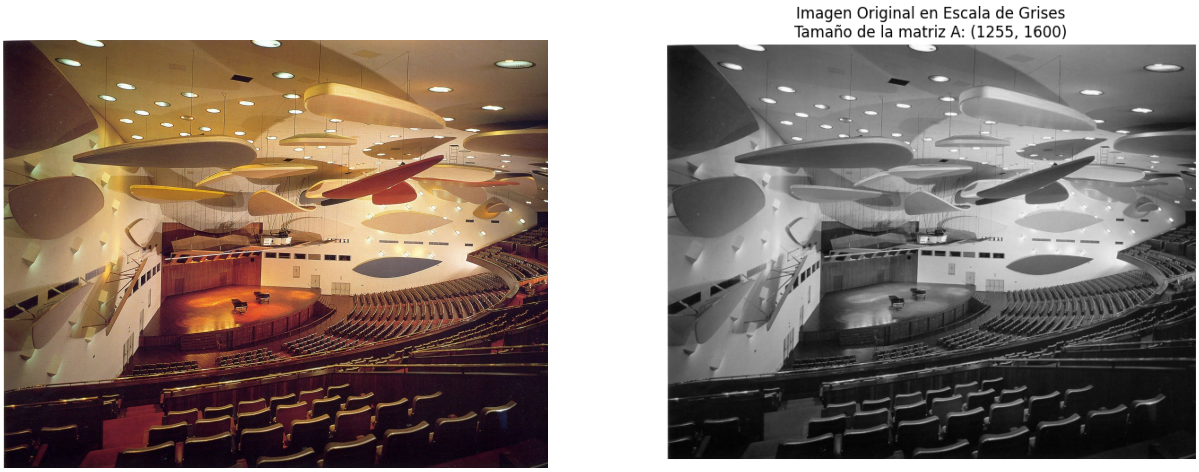

Figura 1: Imagen original del Aula Magna a color (*aula_magna.jpg*, izquierda) y transformada a escala de grises (derecha).

A través de un ciclo iterativo, se reconstruyeron las aproximaciones truncadas A_k para los valores de corte $k \in \{5, 20, 50, 100, 200\}$. Las imágenes resultantes despliegan en la Figura 2.

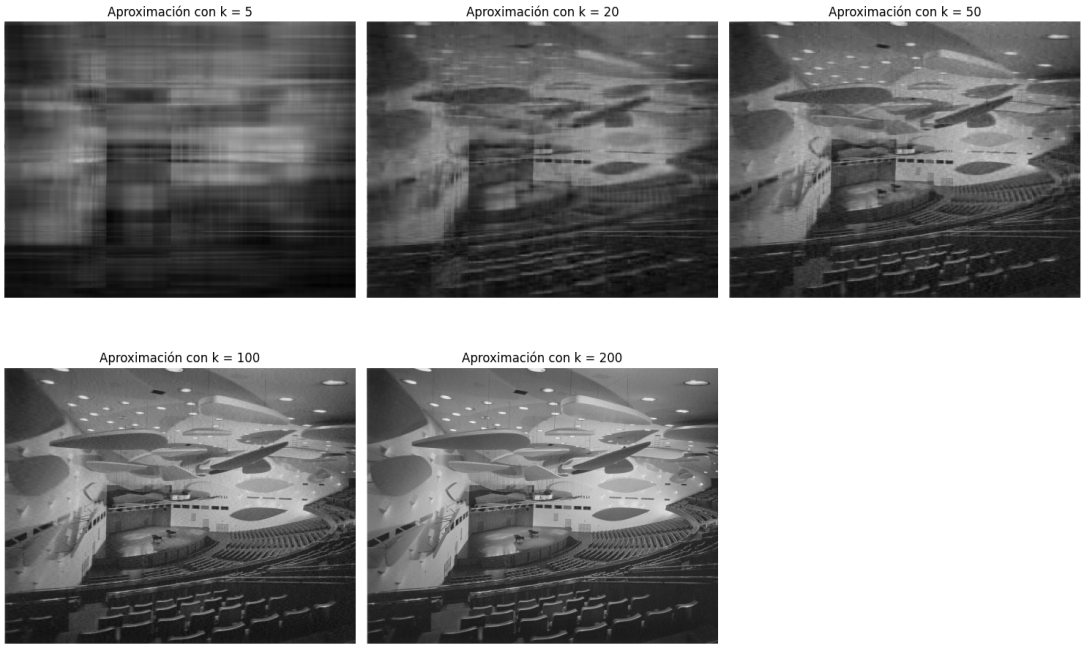

Figura 2: Reconstrucciones visuales de la imagen para distintos rangos de truncamiento k.

Al realizar la inspección visual, se evidencia que para un valor crítico bajo como $k = 5$, la imagen pierde nitidez casi por completo, mostrando únicamente siluetas macroscópicas y contrastes groseros de iluminación. A medida que k se incrementa a 20 y 50, los elementos estructurales se definen notablemente. Para rangos de $k = 100$ y $k = 200$, la aproximación recupera las texturas de alta frecuencia espacial, volviéndose prácticamente idéntica a la fotografía original para el ojo humano.

3.2. Color

Para extender el procedimiento al caso de una imagen a color, se consideró la matriz de entrada como un arreglo tridimensional $M \in \mathbb{R}^{m \times n \times 3}$ bajo el modelo RGB, donde cada píxel está compuesto por tres intensidades asociadas a los canales rojo, verde y azul. Dado que la factorización SVD clásica está definida para matrices bidimensionales, el tensor M se descompuso en tres matrices $R, G, B \in \mathbb{R}^{m \times n}$, y sobre cada una se calculó de forma independiente su descomposición $R = U_R \Sigma_R V_R^T$, $G = U_G \Sigma_G V_G^T$ y $B = U_B \Sigma_B V_B^T$. Para cada valor de truncamiento k, se reconstruyeron las aproximaciones de rango bajo R_k, G_k y B_k tomando únicamente los primeros k valores singulares y sus vectores asociados, y posteriormente se reensamblaron en una aproximación a color M_k apilando los tres canales. Este enfoque permite aplicar de manera efectiva el Teorema de Eckart-Young-Mirsky por canal.

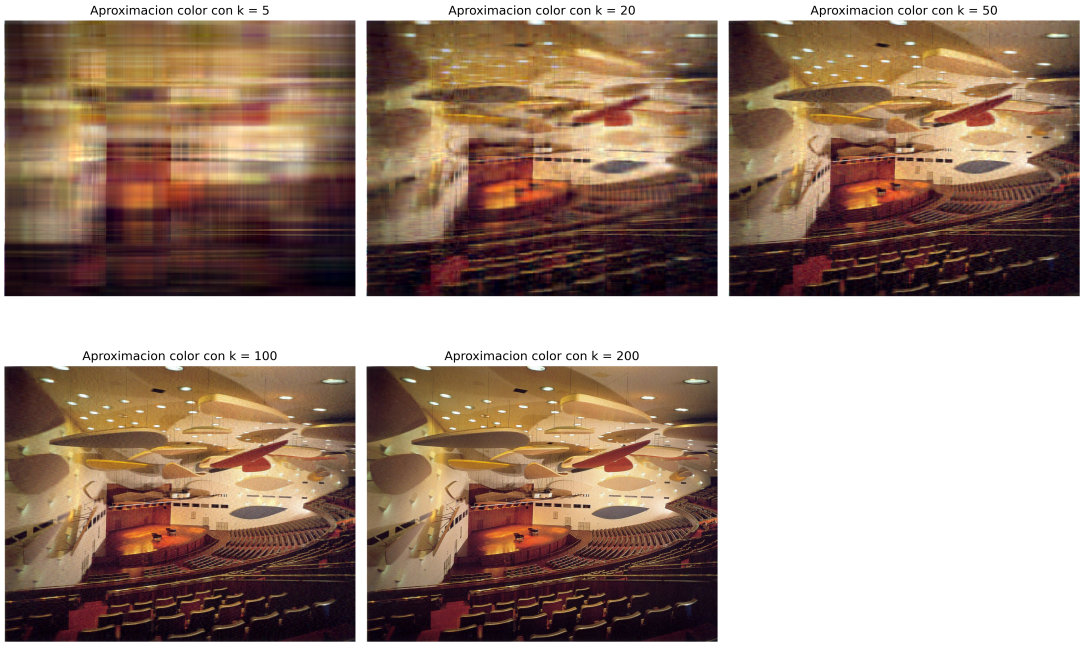

Figura 3: Reconstrucciones visuales de la imagen a color (RGB) para distintos rangos de truncamiento k.

Al realizar la inspección visual de las aproximaciones a color, se observa un comportamiento de convergencia similar al del caso en escala de grises, pero con la adición de artefactos cromáticos evidentes en las primeras iteraciones. Para un valor bajo como $k = 5$, la imagen sufre una distorsión severa, los colores se mezclan de forma errática y no se distingue el contenido. Al incrementar el rango a $k = 20$ y $k = 50$, la estructura del recinto comienza a definirse claramente, aunque la imagen mantiene un aspecto ruidoso y una saturación poco fiel a la realidad. Finalmente, al alcanzar $k = 100$ y $k = 200$, la combinación matricial tridimensional de los canales RGB recupera exitosamente tanto las texturas espaciales como la paleta de colores original, resultando en una reconstrucción de excelente calidad que resulta imperceptiblemente distinta a la fotografía original.

4. Análisis Cuantitativo

4.1. Significado Conceptual de las Métricas

Antes de evaluar los resultados numéricos tabulados, es fundamental definir el significado físico, estadístico y computacional de las tres variables utilizadas para diagnosticar el rendimiento de la aproximación por rango bajo:

- **Relación de Almacenamiento:** Representa cuantitativamente la fracción de memoria física que requiere la estructura comprimida truncada en comparación con el arreglo denso original. Computacionalmente, mide la eficiencia espacial del algoritmo. Un valor de 0,28 denota que solo se necesita el 28 % de los coeficientes numéricos de las matrices factorizadas para reconstruir la imagen, lo que se traduce directamente en una optimización del uso de memoria RAM y almacenamiento al transformar un problema de orden $O(m \times n)$ a uno de orden $O(k(m+n+1))$.

- **Error Relativo:** Cuantifica la pérdida de fidelidad geométrica y numérica mediante la norma de Frobenius, la cual actúa como una métrica de distancia euclidiana en el espacio de matrices $\mathbb{R}^{m \times n}$ representa la magnitud global del residuo o información descartada. Un error relativo cercano a 0,07 indica que la variación local acumulada de las intensidades de los píxeles de la aproximación diverge apenas un 7 % respecto a la fotografía real de origen, un margen tolerado eficientemente por el ojo humano.

- **Energía Capturada:** Conceptualmente está ligada a la varianza estadística de los datos espaciales. Los valores singulares elevados al cuadrado (σ_i^2) equivalen a los autovalores de la matriz de covarianza de la imagen. Por lo tanto, la función de energía acumulada describe qué proporción de la dispersión de información, contrastes estructurales y formas macroscópicas se retiene de forma efectiva en el subespacio de dimensión k. Que los primeros 5 componentes principales capturen más del 92 % de la energía total confirma la enorme redundancia estadística de la información visual analizada.

4.2. Evaluación de Almacenamiento y Tasa de Compresión

La matriz original requiere guardar un total de $m \times n$ coeficientes. Al aplicar la SVD truncada, la estructura de almacenamiento se reduce a guardar exclusivamente los componentes principales requeridos por la combinación lineal, cuyo costo numérico está acotado por $k(m+n+1)$.

Los resultados de almacenamiento obtenidos mediante el procesamiento de datos con la librería `Pandas` se resumen en el Cuadro 1.

Cuadro 1: Métricas cuantitativas de la compresión por SVD.

Rango (k)	**Relación de Almacenamiento**	**Error Relativo**	**Energía Capturada**
5	0.007112	0.266014	0.929236
20	0.028446	0.188465	0.964481
50	0.071116	0.143358	0.979448
100	0.142231	0.109983	0.987904
200	0.284462	0.076198	0.994194

Cuadro 2: Métricas cuantitativas de la compresión por SVD para la imagen a color.

Rango (k)	**Relación de Almacenamiento**	**Error Relativo**	**Energía Capturada**
5	0.007112	0.266777	0.928713
20	0.028446	0.188927	0.964174
50	0.071116	0.143936	0.979209
100	0.142231	0.111019	0.987632
200	0.284462	0.077236	0.994014

4.3. Comportamiento del Error y la Energía

El error relativo formal se evaluó mediante la razón de la norma de Frobenius de la matriz residual sobre la norma de la matriz original ($\|A - A_k\|_F / \|A\|_F$). Paralelamente, el porcentaje de varianza o energía acumulada se computó sumando los cuadrados de los primeros k valores singulares respecto a la suma totalizada de los elementos de Σ.

Las curvas generadas por el script quedaron registradas en el gráfico unificado.

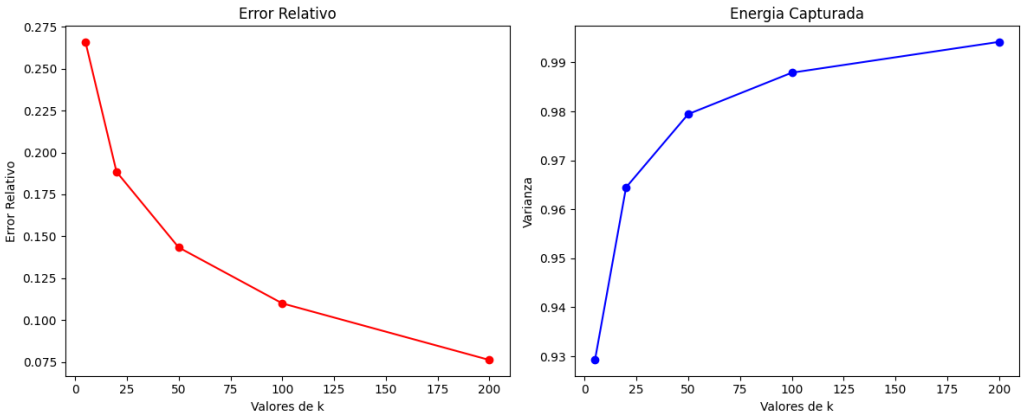

Figura 4: Curvas discretas de Error Relativo (izquierda) y Energía Capturada (derecha) para los valores de k evaluados.

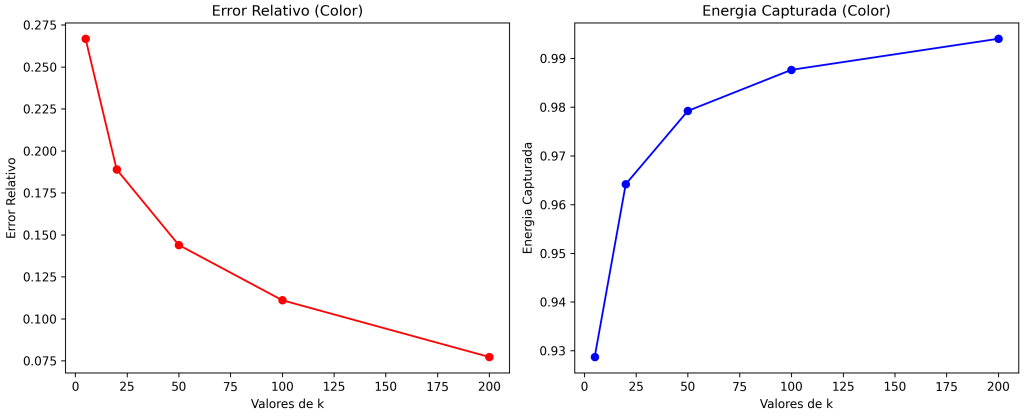

Figura 5: Curvas discretas de Error Relativo (izquierda) y Energía Capturada (derecha) para la matriz tridimensional de la imagen a color en función de k.

El análisis de las gráficas confirma la naturaleza de la descomposición SVD. A pesar de evaluar únicamente cinco puntos discretos, se aprecia claramente cómo el error relativo decae drásticamente a medida que k pasa de 5 a 50, mientras que la curva de energía capturada describe un comportamiento fuertemente cóncavo. Esto demuestra cuantitativamente que la información geométrica fundamental de la imagen se concentra firmemente en los vectores singulares asociados a los primeros componentes algebraicos, permitiendo descartar el resto del espectro sin pérdida semántica significativa.

5. Conclusiones

La experimentación numérica ratifica la utilidad del Teorema de Eckart-Young-Mirsky en problemas de optimización de almacenamiento y computación científica. La descomposición

SVD permite segregar eficientemente los componentes espaciales de una imagen. Las formas generales y los gradientes lumínicos principales se codifican en los valores singulares dominantes, mientras que los detalles minuciosos y el ruido se asocian a los valores mínimos. Se concluye que es posible lograr una reducción sustancial de los datos necesarios para representar la matriz original asegurando un residuo visualmente imperceptible.